

Математические модели обработки сигналов

## Тема 2: SVD


Лектор: Кривошеин А.В.

## Мотивация

Ряд тем будет связан с представлением сигналов в различных базисах. Как правило, при работе с сигналами, полученными из одного источника или из нескольких схожих источников, оказывается, что полученные сигналы в некотором смысле “похожи”.

Это может выражаться в том, что при представлении сигналов в подходящем базисе координаты этих сигналов будут содержать большое количество нулей или значений близких к нулю. Тогда несущественные координаты можно отбросить, что фактически позволяет представить исходные сигналы с помощью векторов сравнительно малой размерности.

Такого типа обработка сигналов называется **снижением размерности данных** и может использоваться для сжатия сигналов. Снижение размерности также может быть полезно как первый шаг иных алгоритмов обработки сигналов в задачах анализа сигналов, в задачах классификации, кластеризации и пр.



Алгоритм, который позволяет строить подходящий, лучший в некотором смысле базис для представления сигналов по имеющемуся набору сигналов, является алгоритм, основанный на **сингулярном разложении матриц** (англ. Singular Value Decomposition, SVD).

В данном случае матрица может представлять собой совокупность сигналов одной длины, где сигналы записаны в строках матрицы. Либо это может быть матрица данных, где записаны числовые признаки некоторого набора объектов. То есть каждый объект описывается в матрицы числовым вектором-строкой.

Далее, матрицу данных будем обозначать  $A \in \mathbb{C}^{m \times n}$ .

## Спектральное разложение

Напомним понятие спектрального разложения квадратных матриц. Для матрицы  $A \in \mathbb{C}^{m \times m}$  матрицу  $A^* = \overline{A}^T$  называют эрмитово-сопряжённой.

**Спектральным разложением** квадратной матрицы  $A$  называют представление этой матрицы с помощью её собственных чисел и собственных векторов.

Напомним, что матрицу  $A \in \mathbb{C}^{m \times m}$  называют нормальной, если  $AA^* = A^*A$ .

Известно, что матрица  $A$  нормальна тогда и только тогда, когда имеет место представление

$$A = Q \Lambda Q^*,$$

где  $Q$  унитарная матрица (то есть  $Q Q^* = I_m$  или  $Q^{-1} = Q^*$ ), а  $\Lambda$  диагональная матрица с собственными числами матрицы  $A$  на диагонали. Это представление и является спектральным разложением.

Иными словами, нормальные матрицы диагонализуемы (и только они).

Кроме того, столбцы  $q_1, \dots, q_m$  матрицы  $Q$  образуют ОНБ пространства  $\mathbb{C}^m$  из собственных векторов матрицы  $A$ . В этом базисе матрица  $A$  имеет наиболее простой диагональный вид.

Если матрица  $A$  вещественная и симметричная (то есть  $A^T = A$ ), то все собственные числа этой матрицы вещественны и матрица  $Q$  ортогональна (то есть  $Q Q^T = I_m$  или  $Q^{-1} = Q^T$ ).

## Сингулярное разложение

**Сингулярное разложения матриц** (далее SVD) является аналогом спектрального разложения, который применим в более общем случае, а именно, **применим для любой прямоугольной матрицы**. SVD широко используется в задачах анализа данных и задачах снижения размерности данных, например, для реализации метода главных компонент (англ. Principal Component Analysis, PCA).

Пусть  $A$  прямоугольная матрица размера  $m \times n$ , определим её SVD. Рассмотрим квадратную матрицу  $B$  размера  $m \times m$  вида  $B = A A^*$ .

Матрицу  $B$  называют матрицей Грамма для матрицы  $A$  (поскольку матрица  $B$  является матрицей Грамма линейного отображения, действие которого задаётся матрицей  $A$ ).

Ясно, что матрица  $B$  является самосопряжённой, то есть  $B = B^*$ . Значит матрица  $B$  нормальна и диагонализуема. При этом матрица  $B$  положительно полу-определена. Действительно,

$$\langle Bx, x \rangle = \langle AA^*x, x \rangle = \langle A^*x, A^*x \rangle = \|A^*x\|^2 \geq 0 \quad \forall x \in \mathbb{C}^m.$$

То есть все собственные числа матрицы  $B$  неотрицательны.

## Сингулярное разложение

Запишем спектральное разложение для матрицы  $B$ :

$$B = U \Lambda U^*,$$

где  $\Lambda$  диагональная матрица с собственными числами матрицы  $B$  на диагонали, а  $U$  унитарная матрица, столбцы которой порождают ОНБ из собственных векторов матрицы  $B$ . Обозначим собственные числа за  $\lambda_j$ ,  $j = 1, \dots, m$ , а соответствующие собственные вектора-столбцы за  $u_j$ , то есть

$$\Lambda = \text{diag} \{ \lambda_1, \dots, \lambda_m \}, \quad U = (u_1, \dots, u_m), \quad B u_j = \lambda_j u_j.$$

Эти матрицы имеют размер  $m \times m$ . Как отмечено выше,  $\lambda_j \geq 0$ . Будем также считать, что собственные числа расположены по убыванию значений. Положим  $\lambda_j = \sigma_j^2$ , где

$$\sigma_1 \geq \dots > \sigma_r > \sigma_{r+1} = \dots = \sigma_m = 0$$

с соглашением, что  $\{\sigma_{r+1}, \dots, \sigma_m\}$  является пустым множеством при  $r = m$ . Эти значения  $\sigma_j$  называют **сингулярными числами** матрицы  $A$ . Таким образом,

$$\Lambda = \text{diag} \{ \sigma_1^2, \dots, \sigma_r^2, 0, \dots, 0 \}.$$

## Сингулярное разложение

Обозначим за  $S_r := \text{diag} \{\sigma_1, \dots, \sigma_r\}$ , рассмотрим матрицу размера  $m \times n$

$$\Sigma = \begin{pmatrix} S_r & \mathbb{O}_{r \times (n-r)} \\ \mathbb{O}_{(m-r) \times r} & \mathbb{O}_{(m-r) \times (n-r)} \end{pmatrix}.$$

При этом  $\Lambda = \Sigma \Sigma^*$  и верны равенства

$$B = U \Lambda U^* = (U \Sigma) (U \Sigma)^*, \text{ причём } \text{rank}(\Sigma) = \text{rank}(\Lambda) = \text{rank}(B) = r.$$

**Теорема** (о полном SVD). Пусть  $A$  является матрицей размера  $m \times n$  с рангом  $\text{rank } A = r$ . Тогда найдутся унитарные матрицы  $U$  размера  $m \times m$  и  $V$  размера  $n \times n$ , такие что

$$A = U \Sigma V^*,$$

где матрица  $\Sigma$  определена выше.

Матрица  $U$  в SVD совпадает с матрицей  $U$  полученной из спектрального разложения матрицы  $B$ , а матрица  $V$  получается специальным построением. Причём, если  $r < \min \{m, n\}$ , то матрицы  $U, V$  можно получить не единственным образом.

При этом, если матрица  $A$  вещественна, то и унитарные матрицы  $U, V$  можно выбрать вещественными.

## Сингулярное разложение


Проиллюстрируем теорему о полном SVD.

Матрица  $A$  размера  $m \times n$  с рангом  $\text{rank } A = r$ .

Матрицы  $U$  размера  $m \times m$  и  $V$  размера  $n \times n$  унитарны.

$$A = U \Sigma V^*, \quad \Sigma = \begin{pmatrix} S_r & \mathbf{0}_{r \times (n-r)} \\ \mathbf{0}_{(m-r) \times r} & \mathbf{0}_{(m-r) \times (n-r)} \end{pmatrix}.$$

Пусть  $m > n$ , то есть матрица данных такова, что объектов больше, чем признаков.



Из иллюстрации ясно, что нет необходимости хранить те столбцы матриц  $U$  и  $V$ , которые умножаются на нули из центральной матрицы. Это является мотивацией для неполного SVD (англ. economy SVD).

## Сингулярное разложение

**Теорема** (теорема о неполном SVD). Пусть  $A$  является матрицей размера  $m \times n$  с рангом  $\text{rank } A = r$ . Тогда найдутся матрицы  $U_r$  размера  $m \times r$  и  $V_r$  размера  $n \times r$ , удовлетворяющие равенствам

$$U_r^* U_r = I_r, \quad V_r^* V_r = I_r, \quad \text{такие что} \quad A = U_r S_r V_r^*,$$

где  $S_r = \text{diag}(\sigma_1, \dots, \sigma_r)$ ,  $\sigma_1 \geq \dots \geq \sigma_r > 0$ .

При этом если матрица  $A$  вещественна, то и матрицы  $U_r$ ,  $V_r$  можно выбрать вещественными.

В теореме о неполном SVD матрицы  $U_r$ ,  $V_r$  находятся единственным образом:

$U_r$  — это первые  $r$  столбцов матрицы  $U$ ,

$$V_r = A^* U_r S_r^{-1}.$$

Ниже проиллюстрированы случаи полного и неполного SVD, когда  $m > n$ .

A	=	<div style="display: flex; justify-content: space-between; height: 100%; border-right: 1px solid black;"> <div style="width: 40%; height: 100%; border-bottom: 1px solid black; vertical-align: middle;">U<sub>r</sub></div> <div style="width: 60%; height: 100%; border-bottom: 1px solid black; vertical-align: middle;">0</div> </div>	<table border="1" style="border-collapse: collapse; text-align: center;"> <tr> <td style="width: 50%; height: 50%;">S<sub>r</sub></td> <td style="width: 50%; height: 50%;">0</td> </tr> <tr> <td style="width: 50%; height: 50%;">0</td> <td style="width: 50%; height: 50%;">0</td> </tr> </table>	S <sub>r</sub>	0	0	0	<table border="1" style="border-collapse: collapse; text-align: center;"> <tr> <td style="width: 100%; height: 50%;">V<sub>r</sub><sup>*</sup></td> </tr> <tr> <td style="width: 100%; height: 50%;">0</td> </tr> </table>	V <sub>r</sub> <sup>*</sup>	0
S <sub>r</sub>	0									
0	0									
V <sub>r</sub> <sup>*</sup>										
0										

A	=	<div style="display: flex; justify-content: space-between; height: 100%; border-right: 1px solid black;"> <div style="width: 40%; height: 100%; border-bottom: 1px solid black; vertical-align: middle;">U<sub>r</sub></div> <div style="width: 60%; height: 100%; border-bottom: 1px solid black; vertical-align: middle;"> <div style="display: flex; justify-content: space-around; width: 100%;"> <div style="width: 40%; height: 100%; border-bottom: 1px solid black; vertical-align: middle;">S<sub>r</sub></div> <div style="width: 60%; height: 100%; border-bottom: 1px solid black; vertical-align: middle;">V<sub>r</sub><sup>*</sup></div> </div> </div> </div>
---	---	--



## Главные компоненты матрицы

Пусть  $A$  является матрицей размера  $m \times n$  с рангом  $\text{rank } A = r$ . Рассмотрим неполное SVD  $A = U_r S_r V_r^*$ .

Пусть  $u_1, \dots, u_r$  вектора-столбцы матрицы  $U_r$ ,  $v_1, \dots, v_r$  вектора-столбцы матрицы  $V_r$ .

Пару векторов-столбцов  $(u_j, v_j)$ ,  $j = 1, \dots, r$ , называют парой **левых и правых сингулярных** векторов матрицы  $A$ , ассоциированных с сингулярным значением  $\sigma_j$ .

Пару векторов  $(v_1, u_1)$  соответствующих наибольшему сингулярному числу  $\sigma_1$ , также называют (первой) **главной компонентой** матрицы  $A$ . Аналогично определяются  $i$ -ые **главные компоненты** матрицы  $A$ .

Переписав вид SVD можно представить матрицу  $A$  как специальную сумму главных компонент.

Пусть  $S_r = S_{r,1} + S_{r,2} + \dots + S_{r,r}$ , где  $S_{r,i} = \text{diag}(0, \dots, 0, \sigma_i, 0, \dots, 0)$ . Тогда

$$A = U_r S_r V_r^* = \sum_{i=1}^r U_r S_{r,i} V_r^* = u_1 \sigma_1 v_1^* + u_2 \sigma_2 v_2^* + \dots + u_r \sigma_r v_r^*.$$

Слагаемыми являются матрицы ранга 1.

## Экстремальное свойство SVD: обозначения

Существует множество различных разложений матрицы. Однако, SVD обладает некоторым экстремальным свойством.

**Определение.** Нормой Фробениуса (или также говорят нормой Гильберта-Шмидта) матрицы  $A \in \mathbb{C}^{m \times n}$  называют норму

$$\|A\|_F = \left( \sum_{j=1}^m \sum_{k=1}^n |a_{j,k}|^2 \right)^{1/2}.$$

**Теорема** (норма Фробениуса равна  $\ell_2$ -норме сингулярных чисел). Пусть  $A \in \mathbb{C}^{m \times n}$  с рангом  $\text{rank } A = r$ . Тогда

$$\|A\|_F = \left( \sum_{j=1}^r \sigma_j^2 \right)^{1/2}, \quad \text{где } \sigma_1, \dots, \sigma_r \text{ сингулярные числа матрицы } A.$$

**Доказательство.** Пусть  $B = A A^*$ . Сначала отметим, что норма Фробениуса матрицы  $B$  согласуется со следом матрицы  $B$ .

$$\text{Tr } B = \sum_{j=1}^m b_{j,j} = \sum_{j=1}^m \left( \sum_{k=1}^n a_{j,k} \overline{a_{j,k}} \right) = \sum_{j=1}^m \sum_{k=1}^n |a_{j,k}|^2 = \|A\|_F^2,$$

Как известно, след матрицы  $\text{Tr } B$  является суммой собственных чисел матрицы  $B$ . Причём собственные числа матрицы  $B$  являются квадратами сингулярных чисел матрицы  $A$

$$\lambda_j = \sigma_j^2, \quad j = 1, \dots, m. \quad \text{Значит} \quad \|A\|_F = \sqrt{\text{Tr } B} = \sqrt{\sum_{j=1}^m \sigma_j^2} = \sqrt{\sum_{j=1}^r \sigma_j^2}, \quad \text{так как } \sigma_{r+1} = \dots = \sigma_m = 0. \bullet$$

## Экстремальное свойство SVD: низкоранговые приближения

Под **наилучшим низкоранговым приближением** матрицы  $A$  понимается матрица того же размера, что и матрица  $A$ , но которая имеет меньший ранг и ближе к исходной матрице по некоторой метрике среди всех других матриц того же ранга.

Рассмотрим метрику, порождённую нормой Фробениуса. Тогда именно SVD решает задачу низкорангового приближения в этой метрике.

SVD матрицы  $A$  имеет вид:  $A = U \Sigma V^* = U_r S_r V_r^*$

$$\boxed{A} = \boxed{U_r} \boxed{S_r} \boxed{V_r^*}$$

где  $U, V$  унитарные матрицы размера  $m \times m, n \times n$ , матрицы  $U_r = (u_1, \dots, u_r), V_r = (v_1, \dots, v_r)$  получены из  $U, V$  сохранением первых  $r$  столбцов,  $\sigma_j$  сингулярные числа матрицы  $A$ , расположенные по убыванию на диагонали матрицы  $S_r$ ,  $S_r = \text{diag}(\sigma_1, \dots, \sigma_r)$ .

Если матрице  $S_r$  сохранить только  $d$  наибольших сингулярных чисел,  $d \leq r$ , то так и будет получено оптимальное приближение матрицы  $A$  с помощью матрицы ранга  $d$ .

## Экстремальное свойство SVD: низкоранговые приближения

Обозначим за  $S_r(d)$  матрицу размера  $r \times r$  вида  $S_r(d) = \text{diag} \{\sigma_1, \dots, \sigma_d, 0, \dots, 0\}$ .

SVD матрицы  $A$  имеет вид:  $A = U_r S_r V_r^*$

Обозначим за  $A(d)$  матрицу:  $A(d) = U_r S_r(d) V_r^* = U_d S_d V_d^*$ ,

где  $U_d, V_d$  — это матрицы, составленные из первых  $d$  столбцов матриц  $U_r, V_r$ ,

$S_d = \text{diag} \{\sigma_1, \dots, \sigma_d\}$ .

Матрицу  $A(d)$  ещё называют сокращённым SVD (англ. truncated SVD). Она решает задачу низкорангового приближения.

Ниже проиллюстрировано различие между неполным и сокращённым SVD.

$$\begin{array}{c}
 \boxed{A} = \boxed{U_r} \boxed{S_r} \boxed{V_r^*} \\
 \\
 \boxed{A(d)} = \boxed{U_d \dots} \begin{array}{|c|c|} \hline S_d & 0 \\ \hline 0 & 0 \\ \hline \end{array} \begin{array}{|c|} \hline V_d^* \\ \hline \dots \\ \hline \end{array} = \boxed{U_d} \boxed{S_d} \boxed{V_d^*}
 \end{array}$$

## Экстремальное свойство SVD: низкоранговые приближения

**Теорема** (о низкоранговых приближениях). Пусть  $A \in \mathbb{C}^{m \times n}$  матрица с рангом  $\text{rank } A = r$  и сингулярными числами  $\sigma_1 \geq \dots \geq \sigma_r > \sigma_{r+1} = \dots = 0$ . Тогда для любого числа  $d$  матрица сокращённого SVD вида

$$A(d) = U_r S_r(d) V_r^*$$

обеспечивает наилучшее приближение матрицы  $A$  с помощью множества всех матриц ранга не выше  $d$  в норме Фробениуса, при этом величина ошибка равна

$$\|A - A(d)\|_F^2 = \sum_{j=d+1}^r \sigma_j^2.$$

Иными словами,

$$\underset{\hat{A}, \text{rank}(\hat{A})=d}{\operatorname{argmin}} \|A - \hat{A}\|_F = A(d) = U_r S_r(d) V_r^*, \quad \text{где } S_r(d) \text{ — матрица размера } r \times r, \quad S_r(d) = \operatorname{diag} \{\sigma_1, \dots, \sigma_d, 0, \dots, 0\}.$$

Более того, известно, что SVD даёт ещё и оптимальное приближение в операторной норме (или спектральной норме).

$$\underset{\hat{A}, \text{rank}(\hat{A})=d}{\operatorname{argmin}} \|A - \hat{A}\|_2 = A(d) = U_r S_r(d) V_r^*, \quad \text{причём } \|A - \hat{A}\|_2 = \sigma_{d+1}.$$

Эта теорема также известна как теорема Экарта-Юнга.