

Математические модели обработки сигналов

Тема 3: Приложения SVD

Лектор: Кривошеин А.В.

Неполное SVD

Теорема (теорема о неполном SVD). Пусть A является матрицей размера $m \times n$ с рангом $\text{rank } A = r$. Тогда найдутся матрицы U_r размера $m \times r$ и V_r размера $n \times r$, удовлетворяющие равенствам

$$U_r^* U_r = I_r, \quad V_r^* V_r = I_r, \quad \text{такие что } A = U_r S_r V_r^*,$$

где $S_r = \text{diag}(\sigma_1, \dots, \sigma_r)$, $\sigma_1 \geq \dots \geq \sigma_r > 0$, σ_i — сингулярные числа матрицы A .

$$\boxed{A} = \boxed{U_r} \boxed{S_r} \boxed{V_r^*}$$

Сокращённое SVD решает задачу наилучшего низкорангового приближения.

$$\underset{\hat{A}, \text{rank}(\hat{A})=d}{\text{argmin}} \|A - \hat{A}\|_F = \underset{\hat{A}, \text{rank}(\hat{A})=d}{\text{argmin}} \|A - \hat{A}\|_2 = A(d),$$

где матрица $A(d)$ имеет вид: $A(d) = U_r S_r(d) V_r^* = U_d S_d V_d^*$, $S_r(d) = \text{diag} \{\sigma_1, \dots, \sigma_d, 0, \dots, 0\}$,

где U_d, V_d — это матрицы, составленные из первых d столбцов матриц U_r, V_r .

Эффективное вычисление SVD осуществляется алгоритмом Голуба-Кахана.

G. Golub and W. Kahan, Calculating the Singular Values and Pseudo-Inverse of a Matrix, SIAM. J. Numer. Anal., Vol. 2, 1965, pp. 202-224

SVD для решения СЛАУ

Многие задачи формулируются в терминах СЛАУ: $Ax = b$,
где матрица A и вектор b известны, а вектор x неизвестен.

Если матрица A квадратна и обратима, то существует единственное решение x для каждого b .

Если матрица A вырождена или прямоугольна, то решение может быть одно, либо решений нет, либо бесконечно много решений в зависимости от вектора b и пространства столбцов матрицы A .

Проанализируем некоторые варианты.

1. Случай недоопределённой системы (англ. under-determined system). В этом случае $A \in \mathbb{C}^{m \times n}$ и $m \ll n$, то есть A узкая-вытянутая (short-fat) матрица или число неизвестных больше числа уравнений. Наиболее вероятно, что столбцы матрицы образуют базис для \mathbb{C}^m (так как количество столбцов n больше размерности пространства m , хотя конечно это и не всегда так, можно взять одинаковые столбцы). Если пространство столбцов матрицы A действительно совпадает с \mathbb{C}^m , то существует бесконечно много решений СЛАУ. Название under-determined system используется потому строк в матрице недостаточно, чтобы единственным образом найти решение x .

2. Случай переопределённой системы (англ. over-determined system). В этом случае $A \in \mathbb{C}^{m \times n}$ и $m \gg n$, то есть A высокая-тонкая (tall-skinny) матрица или число уравнений больше, чем число неизвестных. В этом случае матрица не может иметь m ЛНЗ столбцов, поэтому наиболее вероятно, что решений у СЛАУ нет. Решение (одно или бесконечно много) может быть лишь в том случае, когда b лежит в линейной оболочке столбцов матрицы A .

SVD для решения СЛАУ

Для случая недоопределённой системы, когда есть бесконечно много решений, имеет смысл найти решение x с минимальной нормой (англ. minimum-norm solution), то есть

$$\min_{x \in \mathbb{R}^n: Ax=b} \|x\|_2.$$

Для случая переопределённой системы, когда решений нет, часто имеет смысл получить решение лучшее в средне-квадратичном, то есть то, которое минимизирует норму

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2^2.$$

И SVD позволяет получить решение указанных выше проблем. Для этого введём понятие псевдообратной матрицы.

Псевдообратная матрица

Определение. Пусть $A \in \mathbb{C}^{m \times n}$, $\text{rank } A = r$ и неполное SVD матрицы A имеет вид $A = U_r S_r V_r^*$, где матрицы U_r размера $m \times r$ и V_r размера $n \times r$, удовлетворяющие равенствам

$$U_r^* U_r = I_r, \quad V_r^* V_r = I_r, \quad S_r := \text{diag} \{ \sigma_1, \dots, \sigma_r \}, \quad \sigma_1 \geq \dots \geq \sigma_r > 0$$

σ_j — ненулевые сингулярные числа матрицы A .

Тогда матрицу вида $A^\dagger = V_r S_r^{-1} U_r^*$ называют псевдообратной матрицей Мура-Пенроуза.

Отметим сразу результат произведения матриц A и A^\dagger :

$$A A^\dagger = (U_r S_r V_r^*) (V_r S_r^{-1} U_r^*) = U_r U_r^*,$$

$$A^\dagger A = (V_r S_r^{-1} U_r^*) (U_r S_r V_r^*) = V_r V_r^*.$$

Это квадратные матрицы размера $m \times m$ и $n \times n$, соответственно.

Если A является квадратной невырожденной матрицей, то S_r является квадратной диагональной матрицей с ненулевыми значениями на диагонали и псевдообратная матрица является обратной, поскольку матрицы U_r и V_r будут унитарны.

Псевдообратная матрица и СЛАУ

Вернёмся к СЛАУ $Ax = b$. Построим вектор $x^\square = A^\dagger b$. Если этот вектор подставить обратно в СЛАУ, получим

$$Ax^\square = AA^\dagger b = U_r U_r^* b$$

Здесь матрица $U_r U_r^*$ не обязательно единичная, однако, вектор x^\square обладает следующими свойствами.

Теорема (о решении СЛАУ с помощью псевдообратной матрицы). Пусть $A \in \mathbb{C}^{m \times n}$, $b \in \mathbb{C}^m$, $x^\square = A^\dagger b \in \mathbb{C}^n$.

1. Для всех $x \in \mathbb{C}^n$: $\|Ax^\square - b\| \leq \|Ax - b\|$.
2. Если СЛАУ имеет хотя бы одно решение, то x^\square является решением с наименьшей нормой среди всех любых других решений, то есть $\|x^\square\| \leq \|x\|$, где $Ax = b$.

Таким образом, вектор $x^\square = A^\dagger b$ даёт

1. решение с минимальной нормой, если решений много
2. наилучшее в средне-квадратичном решение, если точного решения нет.

Линейная регрессия

Рассмотрим классическую задачу линейной регрессии: есть набор из m штук однотипных объектов и каждый объект характеризуется набором из n численных признаков. Цель заключается в том, чтобы по известным признакам уметь вычислять некоторый целевой признак. Иными словами, надо построить модель, которая по набору из n численных признаков предсказывает целевой признак.

Решение задачи методом линейной регрессии означает, что модель является линейным отображением вида

$$M(x) = \langle w, x \rangle + b = \sum_{j=1}^n w_j x_j + b, \quad \text{где } x \text{ вектор признаков из } \mathbb{R}^n,$$

где значения вектора w называют весами (англ. weight) модели, а число b — смещением (англ. bias). Набор значений из вектора w и числа b также называют набором параметров модели.

Чтобы найти наиболее подходящие параметры модели необходимы:

A — матрица размера $m \times n$, содержащая данные с признаками,

y — вектор размера $m \times 1$ с известными значениями целевого признака.

Обозначим i -ю строку матрицы A за a_i , это строка содержит набор из n численных признаков i -го объекта,

y_i — это значение целевого признака i -го объекта.

Тогда критерий подбора параметров модели заключается в обеспечении наименьшей средне-квадратичной ошибки на данных, то есть

$$\sum_{i=1}^m |M(a_i) - y_i|^2 = \sum_{i=1}^m |\langle w, a_i \rangle + b - y_i|^2 \rightarrow \min.$$

Линейная регрессия

Для удобства значение смещения можно включить в вектор весов, если в матрицу данных добавить ещё один столбец с фиктивным признаком, значение этого признака для всех объектов равно 1.

Тогда можно считать, что модель имеет вид

$M(x) = \langle w, x \rangle$, а значение ошибки

$$\sum_{i=1}^m |M(a_i) - y_i|^2 = \sum_{i=1}^m |\langle w, a_i \rangle - y_i|^2 = \|A w - y\|^2.$$

Тем самым, для решения задачи линейной регрессии надо решить переопределённую СЛАУ с наилучшим в средне-квадратичном решением. Для этого можно использовать SVD, чтобы построить псевдообратную матрицу к матрице X .

PCA


Метод главных компонент (англ. Principal Component Analysis, далее PCA) — это один из инструментов анализа данных. PCA строим новую координатную систему для более “экономного” представления данных, причём с иерархической структурой (то есть PCA позволяет выделить более существенные координаты от менее важных). PCA основан на SVD.

Рассмотрим матрицу данных вида $A = \begin{pmatrix} a_1 \\ \dots \\ a_m \end{pmatrix}$ размера $m \times n$, здесь a_i — это вектор-строка, содержащая набор из n признаков i -го объекта. Элементы матрицы обозначим $A = \{a_{i,j}\}_{i=1,\dots,m, j=1,\dots,n}$.

Цель PCA в том, чтобы получить матрицу A' размера $m \times d$, где $d < n$, которая представляет тот же набор данных, но с помощью меньшего числа признаков.

Математически это значит, что надо спроектировать исходные n -мерные вектора a_i на d -мерное аффинное подпространство в \mathbb{R}^n , так чтобы сохранить максимум информации о структуре данных.

Аффинное подпространство в \mathbb{R}^n имеет вид $x + L$, где L обычное подпространство в \mathbb{R}^n , а x — некоторый вектор из \mathbb{R}^n .



РСА

Метод главных компонент (англ. Principal Component Analysis, далее PCA) — это один из инструментов анализа данных. PCA строим новую координатную систему для более “экономного” представления данных, причём с иерархической структурой (то есть PCA позволяет выделить более существенные координаты от менее важных). PCA основан на SVD.

Рассмотрим матрицу данных вида $A = \begin{pmatrix} a_1 \\ \dots \\ a_m \end{pmatrix}$ размера $m \times n$, здесь a_i — это вектор-строка, содержащая набор из n признаков i -го объекта. Элементы матрицы обозначим $A = \{a_{i,j}\}_{i=1,\dots,m, j=1,\dots,n}$.

Цель RSA в том, чтобы получить матрицу A' размера $m \times d$, где $d < n$, которая представляет тот же набор данных, но с помощью меньшего числа признаков.

Математически это значит, что надо спроектировать исходные n -мерные вектора a_i на d -мерное аффинное подпространство в \mathbb{R}^n , так чтобы сохранить максимум информации о структуре данных.

Аффинное подпространство в \mathbb{R}^n имеет вид $x + L$, где L обычное подпространство в \mathbb{R}^n , а x — некоторый вектор из \mathbb{R}^n .

Слово "спроектировать" значит, что надо найти подходящее d -мерное аффинное подпространство в \mathbb{R}^n , которое описывается своим ОНБ, далее надо разложить каждый вектор a_i по этому базису, полученные d штук коэффициентов разложения для каждого вектора a_i и будут составлять новую матрицу A' .

Сохранение максимума информации о структуре данных означает, что требуется сохранить информацию об изменчивости данных и топологию данных, то есть взаимное расположение точек a_i относительно друг друга.


PCA

Представим иллюстрацию результата работы метода PCA.

Рассмотрим пример с 5-ю точками из \mathbb{R}^3 .

Цель в том, чтобы снизить размерность представления до 2.

Ниже чёрными точками отмечены исходные точки в \mathbb{R}^3 . Оранжевая плоскость — это подходящее двумерное аффинное подпространство в \mathbb{R}^3 , красные точки — это проекции чёрных точек на выбранное двумерное аффинное подпространство.



Чтобы упростить задачу и вместо проекции на аффинное подпространство рассматривать обычные подпространства, надо центрировать данные. Для этого все вектора a_i , $i = 1, \dots, m$, надо сдвинуть на усреднённый вектор, то есть на вектор

$$a^{\text{av}} = \frac{1}{m} \sum_{j=1}^m a_j. \quad A_{\text{cent}} = \begin{pmatrix} a_1 - a^{\text{av}} \\ \dots \\ a_m - a^{\text{av}} \end{pmatrix}.$$

Тогда центральная точка сдвинутых данных будет находится в начале координат. Далее, будем считать, что в матрице A данные уже отцентрированы.

РСА

Как описывать d -мерные подпространства в \mathbb{R}^n ?

Используем понятие прямоугольных ортогональных матриц. Пусть $1 \leq d \leq n$.

Обозначим за $O_{n,d}$ множество всех $n \times d$ матриц $W = (w_1, \dots, w_d)$, где столбцы этой матрицы $w_i \in \mathbb{R}^n$ попарно ортогональны $\langle w_j, w_k \rangle = \delta_{j-k}$ или $W^T W = I_d$.

Для каждой матрицы $W = (w_1, \dots, w_d) \in O_{n,d}$ её столбцы являются ОНБ для своей линейной оболочки $\text{span}\{w_1, \dots, w_d\}$, которая является d -мерным подпространством в \mathbb{R}^n .

Таким образом, **d -мерные подпространства в \mathbb{R}^n можно характеризовать матрицами из $O_{n,d}$.**

Для каждого вектора $w \in \text{span } W$ существует единственное представление

$$w = \sum_{j=1}^d c_j w_j = W \begin{pmatrix} c_1 \\ \dots \\ c_d \end{pmatrix} = Wc, \quad c_j \in \mathbb{R}.$$

Компоненты вектора $c = (c_1, \dots, c_d)$ называют координатами вектора w в координатной системе с базисом из векторов w_1, \dots, w_d . При этом получить коэффициенты c_1, \dots, c_d для вектора $w \in \text{span } W$ можно так:

$$W^T w = W^T W c = c \quad \text{или} \quad w^T W = c^T.$$

Вектор w из коэффициентов восстанавливается по формулам: $w = Wc$ или $w^T = c^T W^T$.

Иными словами, вектор-строка w^T длины n теперь характеризуется вектором коэффициентов c^T длины d .

PCA

Обсудим применение SVD для метода PCA. Пусть A матрица данных размера $m \times n$. Пусть $\text{rank } A = r$. Её неполное SVD имеет вид $A = U_r S_r V_r^T$, где матрицы U_r размера $m \times r$ и V_r размера $n \times r$, удовлетворяющие равенствам

$$\text{где } U_r^T U_r = I_r, \quad V_r^T V_r = I_r, \quad S_r := \text{diag} \{\sigma_1, \dots, \sigma_r\}, \quad \sigma_1 \geq \dots \geq \sigma_r > 0,$$

$\sigma_j, j = 1, \dots, r$, — это ненулевые сингулярные числа матрицы A .

Пусть $1 \leq d < r$. Рассмотрим сокращённое SVD.

$$A_{\text{cut}} = U_d S_d V_d^T, \quad U_d = (u_1, \dots, u_d), \quad V_d = (v_1, \dots, v_d), \quad S_d = \text{diag}(\sigma_1, \dots, \sigma_d).$$

Отметим, что $V_d \in O_{n,d}$, а значит эта матрица характеризует некоторое d -мерное подпространство в \mathbb{R}^n . Спроектируем вектора-строки матрицы A на это подпространство. Проекции этих векторов будут вектор-строками матрицы $A V_d$. Обозначим

$$Y_d := A V_d$$

РСА

Определение. Пусть $1 \leq d < r$. Вектора-строки y_1, \dots, y_m , составляющие матрицу $Y_d = \begin{pmatrix} y_1 \\ \dots \\ y_m \end{pmatrix}$, называют **представлением**

данных матрицы A **в пространстве меньшей размерности**.

Нахождение этой матрицы Y_d по матрице A и составляет суть РСА.

Чтобы восстановить исходные данные по их представлению в пространстве меньшей размерности вектора, надо использовать строки матрицы Y_d как коэффициенты при векторах, составляющих столбцы матрицы V_d :

$$A_{\text{approx}} := Y_d V_d^T = A V_d V_d^T.$$

Конечно, строки матрицы A_{approx} после проделанного снижения размерности будут лишь приближением строк исходной матрицы A , так как при снижении размерности неизбежно теряется информация. Тем не менее, это приближение в некотором смысле оптимально.

РСА

Теорема (об оптимальном снижении размерности данных). Пусть $A \in \mathbb{R}^{m \times n}$ матрица центрированных данных с неполным SVD вида $A = U_r S_r V_r^T$.

Тогда представление данных матрицы A в меньшей размерности с помощью матрицы

$$Y_d = \begin{pmatrix} y_1 \\ \dots \\ y_m \end{pmatrix} = A V_d \text{ удовлетворяет неравенству } \sum_{i=1}^m \|y_i V_d^T - a_i\|^2 \leq \sum_{i=1}^m \|q_i W_d^T - a_i\|^2$$

для всех матриц $W_d \in O_{n,d}$ и всех векторов-строк $q_1, \dots, q_m \in \mathbb{R}^d$.

Перефразируя эту теорему можно сказать, что

любое другое d -мерное подпространство в \mathbb{R}^n с ОНБ в виде столбцов матрицы $W_d \in O_{n,d}$ и

любой набор из m штук векторов в этом подпространстве

не даёт приближение лучше, чем представление данных матрицы A в пространстве меньшей размерности с помощью матрицы Y_d .

Итак, d правых сингулярных векторов v_1, \dots, v_d (столбцов матрицы V_d) задают лучшую координатную систему для оптимального снижения размерности n -мерных строк матрицы A до d -мерных, $d < n$. Эти вектора v_1, \dots, v_d и называют **главными компонентами** матрицы данных A .

В частности, для снижения к 1-мерному подпространству используется 1-ая главная компонента v_1 , порождающая подпространство для представления данных с помощью одной размерности.

Для снижения к 2-мерному представлению используются первые две главных компоненты v_1, v_2 и так далее.

РСА

Когда данные матрицы A не центрированы, то их необходимо центрировать, чтобы затем применять процесс снижения размерности данных к центрированной матрице A_{cent} .

Если мы получили приближения векторов матрицы A_{cent} векторами $Y_d V_d^T$, то приближения для векторов исходной матрицы получаются в виде

$$y_1 V_d^T + a^{\text{av}}, \dots, y_m V_d^T + a^{\text{av}}.$$

Итоговая ошибка приближения данных исходной матрицы имеет вид

$$\left\| A_{\text{cent}} V_d V_d^* + \begin{pmatrix} a^{\text{av}} \\ \dots \\ a^{\text{av}} \end{pmatrix} - A \right\|_F.$$

Выше метод РСА применялся для того, чтобы модифицировать пространство признаков. Но аналогичным образом можно решать задачу уменьшения данных, как снижение числа записей об объектах, то есть уменьшения числа строк матрицы m . Для этого надо лишь транспонировать эту матрицу и применить метод РСА к этой матрице.